

LAPORAN PROJECT TUGAS AKHIR KECERDASAN ARTIFICIAL

**KLASTERISASI DAN SISTEM REKOMENDASI DESTINASI WISATA DI
INDONESIA MENGGUNAKAN K-MEANS DAN CONTENT-BASED FILTERING**

Disusun untuk memenuhi Project Tugas Akhir Mata Kuliah Kecerdasan Artificial

Dosen pengampu:

1. Ibu Yuni Rosita Dewi, M.Si.



Disusun Oleh :

1. Kartika Nur Savira (24031554049)
2. Sabrina Putri Amalia (24031554055)
3. Variesa Sabita Mumtaza Habib (24031554083)

SEMESTER 3

PROGRAM STUDI S1 SAINS DATA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS NEGERI SURABAYA

DESEMBER 2025

DAFTAR ISI

DAFTAR ISI	1
BAB I PENDAHULUAN	3
1.1. LATAR BELAKANG	3
1.2. TUJUAN	4
1.3. MANFAAT	4
1.4. SUMBER DATA	4
BAB II LANDASAN TEORI	6
2.1. CLUSTERING	6
2.2. K-MEANS	6
2.3. CONTENT-BASED FILTERING	6
BAB III METODOLOGI	7
3.1. DIAGRAM ALUR	7
3.2. DATA COLLECTING	7
3.3. PREPROCESSING	7
3.4. FEATURE ENGINEERING	8
3.5. K-MEANS CLUSTERING	8
3.6. PENENTUAN JUMLAH CLUSTER OPTIMAL	9
3.7. KLASTERISASI MENGGUNAKAN K-MEANS	9
3.8. ANALISIS STATISTIK SETIAP CLUSTER	9
3.9. VISUALISASI HASIL KLASTERISASI	10
3.10. SISTEM REKOMENDASI TEMPAT WISATA	10
3.10.1. Pembentukan Fitur Teks dan TF-IDF	10
3.10.2. Perhitungan Jarak Geografis	10
3.10.3. Metode Hybrid Recommendation	10
3.10.4. Implementasi Menu Interaktif	10
BAB IV HASIL DAN PEMBAHASAN	11
4.1. HASIL DATA COLLECTING	11
4.2. HASIL PREPROCESSING DATA	11
4.3. PENENTUAN JUMLAH CLUSTER (K) OPTIMAL	12
4.3.1. Elbow Method	12
4.3.2. Silhouette Score	13
4.4. HASIL K-MEANS CLUSTERING	13
4.4.1. Cluster 0 : Wisata Murah dengan Rating Relatif Rendah	13
4.4.2. Cluster 1 : Wisata Mahal dengan Rating Tinggi	14
4.4.3. Cluster 2 : Wisata Spesifik	14
4.4.4. Cluster 3 : Wisata Murah dengan Rating Tinggi	14
4.4.5. Cluster 4 : Wisata Murah dan Populer	14
4.5. HASIL VISUALISASI	15
4.5.1. Scatter Plot	15
4.5.2. Boxplot	16

4.5.3. Bar Chart	17
4.6. HASIL SISTEM REKOMENDASI HYBRID	18
4.7. KELEBIHAN DAN KEKURANGAN SISTEM	19
BAB V PENUTUP	20
5.1. KENDALA	20
5.2. SOLUSI	21
5.3. KESIMPULAN	23
DAFTAR PUSTAKA	24
<i>Lampiran</i>	25

BAB I PENDAHULUAN

1.1. LATAR BELAKANG

Indonesia merupakan salah satu negara dengan kekayaan destinasi wisata terbesar di dunia. Ribuan tempat wisata tersebar dari Sabang hingga Merauke, mencakup berbagai jenis atraksi seperti wisata alam, budaya, sejarah, kuliner, hingga hiburan modern. Keberagaman pilihan ini memberikan keuntungan bagi wisatawan, namun di sisi lain justru menimbulkan tantangan baru. Banyak wisatawan mengalami kebingungan dalam menentukan destinasi yang paling sesuai dengan kebutuhan, preferensi, serta anggaran perjalanan mereka.

Di era digital saat ini, wisatawan biasanya mencari informasi melalui internet, media sosial, atau ulasan di platform wisata. Namun, banyaknya sumber informasi dengan kualitas yang beragam membuat proses pencarian menjadi tidak efisien. Wisatawan harus membandingkan harga, rating, kategori wisata, hingga lokasi secara manual, yang membutuhkan waktu lama dan sering kali menghasilkan keputusan yang kurang optimal. Tanpa adanya sistem rekomendasi yang terstruktur, pengguna hanya mengandalkan preferensi subjektif atau rekomendasi umum yang belum tentu cocok dengan kebutuhan pribadi mereka.

Untuk mengatasi masalah ini, diperlukan pendekatan berbasis data yang mampu mengelompokkan destinasi secara otomatis dan memberikan rekomendasi yang lebih relevan. Salah satu metode yang efektif adalah K-Means Clustering, sebuah algoritma machine learning tanpa supervisi yang dapat mengelompokkan objek berdasarkan kemiripan karakteristik tertentu, seperti harga tiket masuk, rating pengunjung, popularitas, atau jenis wisata. Dengan memetakan destinasi ke dalam beberapa cluster, wisatawan dapat dengan mudah memahami kelompok wisata berdasarkan level harga atau kualitasnya.

Selain itu, penerapan Content-Based Filtering memungkinkan sistem rekomendasi bekerja lebih personal. Metode ini memberikan rekomendasi tempat wisata berdasarkan kemiripan fitur antara destinasi yang pernah disukai pengguna dengan destinasi lainnya. Jika seorang wisatawan menyukai destinasi bertema alam dengan harga terjangkau dan rating tinggi, maka sistem otomatis akan mencari destinasi lain dalam cluster atau kategori yang serupa. Dengan demikian, rekomendasi menjadi lebih relevan, akurat, dan sesuai preferensi masing-masing pengguna.

Melalui kombinasi antara klasterisasi K-Means dan metode Content-Based Filtering, sistem rekomendasi wisata dapat membantu wisatawan membuat keputusan yang lebih cepat, tepat, dan efisien. Pendekatan ini tidak hanya mengoptimalkan pengalaman wisatawan, tetapi juga bisa digunakan oleh pengelola destinasi atau platform wisata untuk meningkatkan pelayanan dan keterjangkauan informasi kepada publik.

1.2. TUJUAN

- A. Mengelompokkan destinasi wisata di Indonesia menggunakan algoritma K-Means berdasarkan atribut tertentu
- B. Menganalisis hasil klaster yang terbentuk untuk memahami karakteristik setiap grup wisata.
- C. Mengembangkan sistem rekomendasi berbasis Content-Based Filtering untuk memberikan rekomendasi wisata sesuai preferensi pengguna.
- D. Membantu wisatawan dalam menemukan destinasi wisata yang relevan dan sesuai Kebutuhan

1.3. MANFAAT

- A. Untuk wisatawan: mempermudah menemukan rekomendasi wisata yang sesuai preferensi tanpa harus mencari secara manual.
- B. Untuk pihak pariwisata: mengetahui pengelompokan destinasi sehingga dapat digunakan dalam strategi promosi.
- C. Untuk pengembang sistem: menyediakan model rekomendasi yang dapat dikembangkan menjadi aplikasi nyata.

1.4. SUMBER DATA

Dalam pembuatan project Kecerdasan Artificial (KA) sebagai tugas akhir mata kuliah KA, kami mengembangkan sistem rekomendasi destinasi wisata di Indonesia sebagai implementasi konsep sistem rekomendasi berbasis data. Pada proyek ini, kami menggunakan dataset dari Kaggle yang berjudul “Indonesia Tourism Simple Recommendation”. Dari beberapa file yang tersedia, kami mengambil file `tourism_with_id` dan melakukan seleksi kolom sesuai kebutuhan pemodelan. Adapun kolom yang kami gunakan adalah `Place_Id`, `Place_Name`, `Description`, `Category`, `City`, `Price`, `Rating`, karena mampu merepresentasikan

identitas tempat wisata, informasi deskriptif untuk pemrosesan berbasis konten, serta rating sebagai indikator utama preferensi pengguna. Berdasarkan fitur tersebut, kami membangun model rekomendasi yang relevan sekaligus memenuhi tujuan pembelajaran mata kuliah KA.

BAB II LANDASAN TEORI

2.1. CLUSTERING

Clustering adalah teknik pengelompokan data berdasarkan tingkat kemiripan (similarity) antar objek. Tujuan utama clustering adalah mengelompokkan data menjadi beberapa cluster sehingga objek dalam satu cluster memiliki karakteristik yang lebih mirip satu sama lain dibandingkan dengan objek di cluster lain. Clustering termasuk dalam kategori *unsupervised learning* karena tidak membutuhkan label kelas pada data. Dalam clustering, setiap objek direpresentasikan dalam bentuk fitur numerik sehingga jarak atau kemiripan antar objek dapat dihitung. Beberapa konsep penting dalam clustering antara lain seperti Similarity / Dissimilarity yaitu ukuran kemiripan antar objek. Biasanya dihitung menggunakan jarak Euclidean, Centroid yaitu titik pusat cluster.

2.2. K-MEANS


K-Means merupakan algoritma clustering yang bertujuan membagi dataset menjadi K cluster berdasarkan kedekatan jarak dengan pusat cluster (*centroid*). Algoritma ini termasuk salah satu metode paling populer karena cepat, sederhana, dan efektif untuk dataset berskala besar. Pada project ini, K-Means digunakan untuk mengelompokkan destinasi wisata berdasarkan fitur numerik (misal: harga tiket dan rating), menentukan cluster sehingga destinasi wisata yang mirip berada dalam kelompok yang sama. Hasil cluster tersebut digunakan oleh sistem rekomendasi Content-Based Filtering.

2.3. CONTENT-BASED FILTERING

Content-Based Filtering (CBF) adalah metode sistem rekomendasi yang memberikan rekomendasi berdasarkan kemiripan fitur antara item yang disukai pengguna dengan item lainnya. Sistem ini tidak memerlukan data pengguna lain sehingga cocok digunakan saat data interaksi pengguna masih sedikit (*cold-start user*). Dalam project ini pengguna akan memilih satu destinasi wisata yang disukai, sistem mencari cluster tempat tersebut (hasil K-Means), sistem merekomendasikan destinasi lain yang berada dalam cluster yang sama.

BAB III METODOLOGI

3.1. DIAGRAM ALUR



3.2. DATA COLLECTING

Tahap *data collecting* merupakan langkah awal untuk memperoleh data yang relevan dalam pengembangan sistem rekomendasi berbasis Kecerdasan Artificial. Pada proyek ini, pengumpulan data dilakukan melalui platform Kaggle karena menyediakan dataset yang mudah diakses dan terstruktur. Dataset yang digunakan berjudul Indonesia Tourism Simple Recommendation, yang berisi beberapa file terkait destinasi wisata di Indonesia.

Data yang digunakan merupakan dataset tempat wisata di Indonesia yang disimpan dalam file *tourism_with_id.csv*. Dataset tersebut memuat informasi penting seperti nama tempat wisata, kota, kategori, harga tiket (Price), rating, serta koordinat geografis berupa latitude (Lat) dan longitude (Long). Data dimuat menggunakan pustaka **Pandas** untuk memudahkan proses pengolahan dan analisis data. Selain itu, penelitian ini juga menyiapkan layanan *geocoding* menggunakan **Geopy** dengan **Nominatim**, yang berfungsi untuk memperoleh koordinat lokasi berdasarkan nama kota apabila tidak tersedia secara langsung di dataset.

3.3. PREPROCESSING

Tahap pra-pemrosesan dilakukan untuk memastikan kualitas data sebelum dianalisis lebih lanjut. Pertama, baris data yang tidak memiliki informasi koordinat geografis (latitude dan longitude) dihapus karena tidak dapat digunakan dalam perhitungan jarak. Selanjutnya,

nilai *Price* yang kosong diisi menggunakan nilai median berdasarkan kategori tempat wisata, sehingga tetap merepresentasikan karakteristik harga dalam kategori tersebut. Nilai *Rating* yang hilang diisi menggunakan median keseluruhan rating. Setelah proses pengisian dilakukan, data yang masih mengandung nilai kosong dihapus. Tahapan ini bertujuan untuk menghasilkan dataset yang bersih, konsisten, dan siap digunakan pada proses klasterisasi dan sistem rekomendasi.

3.4. FEATURE ENGINEERING

Tahap feature engineering dilakukan untuk menyiapkan dan membentuk fitur-fitur yang relevan sebelum proses klasterisasi dan sistem rekomendasi diterapkan. Pada tahap ini, fitur pada dataset dibagi menjadi dua kelompok utama, yaitu fitur numerik dan fitur teks.

Fitur numerik meliputi *Price*, *Rating*, serta koordinat geografis *Latitude* dan *Longitude*. Fitur-fitur ini dipilih karena merepresentasikan karakteristik utama destinasi wisata yang dapat dihitung secara kuantitatif. Fitur numerik tersebut selanjutnya digunakan sebagai input utama dalam proses K-Means clustering untuk mengelompokkan destinasi wisata berdasarkan kemiripan karakteristik.

Selain itu, dilakukan pula pembentukan fitur teks dengan menggabungkan beberapa atribut, yaitu *Place_Name*, *City*, dan *Category*, menjadi satu kolom teks gabungan. Fitur teks ini digunakan dalam proses TF-IDF untuk mengukur tingkat kemiripan konten antar destinasi wisata pada metode content-based filtering.

Dengan dilakukannya feature engineering, data menjadi lebih terstruktur dan informatif sehingga dapat meningkatkan kinerja proses klasterisasi dan sistem rekomendasi yang dibangun.

3.5. K-MEANS CLUSTERING

Setelah preprocessing, data disiapkan untuk proses klasterisasi dengan memilih atribut numerik utama, yaitu *Price*, *Rating*, *Lat*, dan *Long*. Seluruh atribut tersebut kemudian dilakukan normalisasi menggunakan *StandardScaler* agar setiap fitur memiliki skala yang sebanding. Normalisasi ini penting karena algoritma K-Means sangat sensitif terhadap perbedaan skala data, sehingga tanpa normalisasi hasil klasterisasi dapat menjadi tidak optimal.

3.6. PENENTUAN JUMLAH CLUSTER OPTIMAL

3.6.1. Elbow Method

Metode Elbow digunakan untuk menentukan jumlah cluster yang paling optimal dengan menghitung nilai Within-Cluster Sum of Squares (WCSS) untuk berbagai nilai K, mulai dari 2 hingga 10. Nilai WCSS menunjukkan tingkat kekompakan data dalam suatu cluster. Hasil perhitungan kemudian divisualisasikan dalam bentuk grafik Elbow, di mana titik siku (elbow) menunjukkan jumlah cluster yang memberikan keseimbangan terbaik antara kompleksitas model dan kualitas klasterisasi.

3.6.2. Silhouette Score

Selain Elbow Method, penelitian ini juga menggunakan Silhouette Score untuk mengevaluasi kualitas klasterisasi. Silhouette Score mengukur seberapa baik suatu data berada di dalam clusternya dibandingkan dengan cluster lain. Nilai skor yang semakin mendekati 1 menunjukkan kualitas klasterisasi yang semakin baik. Jumlah cluster dengan nilai Silhouette Score tertinggi dipilih sebagai jumlah cluster optimal (*best_k*) yang digunakan pada tahap K-Means clustering.

3.7. KLASTERISASI MENGGUNAKAN K-MEANS

Proses klasterisasi dilakukan menggunakan algoritma K-Means dengan jumlah cluster optimal yang telah ditentukan sebelumnya. Algoritma ini bekerja dengan mengelompokkan data berdasarkan kedekatan jarak terhadap pusat cluster (centroid). Hasil klasterisasi kemudian disimpan dalam kolom baru bernama *Cluster* pada dataset. Distribusi jumlah data pada setiap cluster dianalisis untuk melihat pola penyebaran tempat wisata berdasarkan harga, rating, dan lokasi geografis.

3.8. ANALISIS STATISTIK SETIAP CLUSTER

Untuk memahami karakteristik masing-masing cluster, dilakukan analisis statistik deskriptif pada atribut *Price* dan *Rating*. Statistik yang dihitung meliputi nilai rata-rata (mean), nilai minimum, maksimum, serta jumlah data pada setiap cluster. Analisis ini memberikan gambaran umum mengenai segmentasi tempat wisata, seperti cluster dengan harga tinggi dan rating tinggi, maupun cluster dengan harga rendah tetapi memiliki tingkat kepuasan yang baik.

3.9. VISUALISASI HASIL KLASTERISASI

Hasil klasterisasi divisualisasikan menggunakan beberapa metode. Visualisasi *scatter plot* digunakan untuk melihat penyebaran data berdasarkan *Price* dan *Rating* serta posisi centroid masing-masing cluster. Selain itu, *boxplot* digunakan untuk menampilkan distribusi harga dan rating pada setiap cluster, sehingga perbedaan karakteristik antar cluster dapat terlihat lebih jelas. Diagram batang (*bar chart*) juga digunakan untuk menunjukkan jumlah tempat wisata pada setiap cluster.

3.10. SISTEM REKOMENDASI TEMPAT WISATA

3.10.1. Pembentukan Fitur Teks dan TF-IDF

Sistem rekomendasi dibangun menggunakan pendekatan *content-based filtering*. Informasi teks berupa nama tempat wisata, kota, dan kategori digabungkan menjadi satu kolom teks. Data teks tersebut kemudian diubah menjadi representasi numerik menggunakan TF-IDF Vectorizer, sehingga kemiripan antar tempat wisata dapat dihitung menggunakan *cosine similarity*.

3.10.2. Perhitungan Jarak Geografis

Untuk mempertimbangkan faktor lokasi, jarak antara lokasi pengguna dan tempat wisata dihitung menggunakan metode geodesic distance. Apabila pengguna hanya memasukkan nama kota, sistem akan menentukan koordinat pusat kota tersebut baik dari dataset maupun melalui layanan Geopy.

3.10.3. Metode Hybrid Recommendation

Sistem rekomendasi yang dikembangkan menggunakan pendekatan hybrid, yaitu menggabungkan beberapa faktor penilaian, meliputi jarak lokasi, kemiripan teks (similarity), rating, dan harga. Setiap faktor dinormalisasi dan diberi bobot tertentu untuk menghasilkan *hybrid score*. Tempat wisata dengan nilai *hybrid score* tertinggi direkomendasikan kepada pengguna sebagai rekomendasi terbaik.

3.10.4. Implementasi Menu Interaktif

Sebagai tahap akhir, sistem dilengkapi dengan menu interaktif berbasis teks. Menu ini memungkinkan pengguna untuk melihat karakteristik setiap cluster atau

mendapatkan rekomendasi tempat wisata berdasarkan kota, radius jarak, budget, dan rating minimum. Dengan adanya menu ini, sistem dapat digunakan secara langsung dan mudah oleh pengguna.

BAB IV HASIL DAN PEMBAHASAN

4.1. HASIL DATA COLLECTING

Tahap data collecting merupakan tahap awal dalam penelitian ini, yang bertujuan untuk mengumpulkan data destinasi wisata yang akan digunakan sebagai dasar proses klasterisasi dan sistem rekomendasi. Dataset yang digunakan terdiri dari 437 tempat wisata yang tersebar di beberapa kota besar di Indonesia.

Data yang dikumpulkan mencakup berbagai atribut penting, antara lain nama tempat wisata, kategori wisata, kota, harga tiket masuk (Price), rating pengguna, serta koordinat geografis berupa latitude dan longitude. Data ini diperoleh dalam bentuk dataset terstruktur sehingga dapat langsung diproses ke tahap selanjutnya.

Hasil dari tahap data collecting ini menunjukkan bahwa dataset memiliki variasi yang cukup beragam baik dari segi harga, rating, kategori wisata, maupun lokasi geografis, sehingga layak digunakan untuk proses analisis lebih lanjut.

4.2. HASIL PREPROCESSING DATA

Tahap preprocessing dilakukan untuk memastikan dataset siap digunakan dalam proses klasterisasi dan pembangunan sistem rekomendasi. Dataset yang digunakan terdiri dari berbagai informasi seperti nama tempat wisata, kategori, kota, harga tiket masuk (Price), rating pengguna, serta koordinat geografis berupa latitude dan longitude.

Pada tahap awal preprocessing dilakukan pemeriksaan missing value. Hasil pemeriksaan menunjukkan adanya missing value pada beberapa kolom numerik, terutama pada kolom Price, Rating, Latitude, dan Longitude. Kolom koordinat (latitude dan longitude) tidak dapat diisi menggunakan metode imputasi karena setiap lokasi memiliki koordinat yang bersifat unik. Oleh karena itu, baris data yang tidak memiliki informasi koordinat dihapus dari dataset.

Sementara itu, nilai kosong pada kolom Price diisi menggunakan nilai median berdasarkan kategori wisata agar nilai yang dihasilkan tetap representatif sesuai dengan jenis wisatanya. Selanjutnya, nilai kosong pada kolom Rating diisi menggunakan median keseluruhan karena distribusi rating relatif seragam.

Tahap berikutnya adalah normalisasi data menggunakan metode StandardScaler. Kolom Price, Rating, Latitude, dan Longitude dinormalisasi ke dalam skala standar dengan nilai mean mendekati 0 dan standar deviasi mendekati 1. Proses normalisasi ini sangat penting karena algoritma K-Means sensitif terhadap perbedaan skala data. Tanpa normalisasi, fitur dengan nilai besar seperti harga akan mendominasi perhitungan jarak.

Rangkaian proses preprocessing ini menghasilkan dataset yang bersih, bebas dari missing value kritis, dan siap digunakan untuk proses klusterisasi serta pembangunan sistem rekomendasi.

4.3. PENENTUAN JUMLAH CLUSTER (K) OPTIMAL

Penentuan jumlah cluster (K) yang optimal dalam proses klusterisasi dilakukan dengan menggunakan dua metode analisis, yaitu *Elbow Method* dan *Silhouette Score*. Kedua metode ini digunakan untuk memastikan bahwa nilai K yang dipilih benar-benar mewakili struktur data secara maksimal, sehingga hasil pengelompokan menjadi lebih akurat, stabil, dan mudah diinterpretasikan.

4.3.1. Elbow Method

Elbow Method dilakukan dengan menghitung nilai WCSS (Within Cluster Sum of Squares) untuk nilai K dari 2 hingga 10. Hasil perhitungan menunjukkan bahwa nilai WCSS mengalami penurunan signifikan pada K kecil dan mulai melandai setelah K=4 hingga K=5.

Berdasarkan pola tersebut, titik siku (elbow) terlihat berada di sekitar K = 3 hingga K = 5. Namun, karena Elbow Method bersifat visual dan subjektif, maka diperlukan validasi tambahan menggunakan Silhouette Score.

4.3.2. Silhouette Score

Silhouette Score digunakan untuk mengevaluasi kualitas pemisahan antar cluster secara numerik. Hasil perhitungan menunjukkan bahwa nilai Silhouette Score tertinggi diperoleh pada K = 5 dengan nilai 0,4272.

Nilai ini menunjukkan bahwa pemisahan cluster pada $K=5$ cukup jelas dan stabil dibandingkan nilai K lainnya. Oleh karena itu, jumlah cluster optimal yang digunakan pada penelitian ini adalah $K = 5$.

4.4. HASIL K-MEANS CLUSTERING

Setelah jumlah cluster optimal ditentukan, algoritma K-Means diterapkan dengan $K = 5$. Hasil klasterisasi menghasilkan distribusi data sebagai berikut:

- Cluster 0: 54 tempat wisata
- Cluster 1: 16 tempat wisata
- Cluster 2: 1 tempat wisata
- Cluster 3: 168 tempat wisata
- Cluster 4: 198 tempat wisata

Setiap cluster merepresentasikan segmen wisata dengan karakteristik yang berbeda berdasarkan harga, rating, dan lokasi.

4.4.1. Cluster 0 : Wisata Murah dengan Rating Relatif Rendah

Rata-rata Price: Rp 17,981
Rata-rata Rating: 4.05
Price Range: Rp 0 - Rp 150,000
Rating Range: 3.4 - 4.2

Cluster ini memiliki rata-rata harga Rp 17.981 dan rata-rata rating 4.05. Tempat wisata pada cluster ini didominasi oleh kategori taman hiburan dan tersebar di kota Bandung, Semarang, dan Yogyakarta.

4.4.2. Cluster 1 : Wisata Mahal dengan Rating Tinggi

Rata-rata Price: Rp 284,375
Rata-rata Rating: 4.47
Price Range: Rp 150,000 - Rp 900,000
Rating Range: 4.0 - 4.8

Cluster ini memiliki harga tertinggi dengan rata-rata Rp 284.375 dan rating rata-rata 4.47. Cluster ini mencerminkan wisata premium dengan jumlah tempat yang relatif sedikit.

4.4.3. Cluster 2 : Wisata Spesifik

Rata-rata Price: Rp 175,000
Rata-rata Rating: 4.40
Price Range: Rp 175,000 - Rp 175,000
Rating Range: 4.4 - 4.4

Cluster ini hanya terdiri dari satu tempat wisata dengan karakteristik yang sangat spesifik, yaitu harga Rp 175.000 dan rating 4.4.

4.4.4. Cluster 3 : Wisata Murah dengan Rating Tinggi

Rata-rata Price: Rp 15,542
Rata-rata Rating: 4.51
Price Range: Rp 0 - Rp 150,000
Rating Range: 4.2 - 5.0

Cluster ini berisi 168 tempat wisata dengan harga rendah dan rating tinggi, didominasi oleh wisata budaya di Bandung dan Jakarta.

4.4.5. Cluster 4 : Wisata Murah dan Populer

Rata-rata Price: Rp 12,455
Rata-rata Rating: 4.49
Price Range: Rp 0 - Rp 150,000
Rating Range: 4.2 - 5.0

Cluster ini merupakan cluster terbesar dengan 198 tempat wisata. Harga relatif murah dan rating tinggi menjadikan cluster ini sebagai segmen wisata paling dominan.

K-Means berhasil memisahkan tempat wisata berdasarkan pola harga, rating, dan lokasi. Tiap cluster merepresentasikan segmen pasar wisata. Informasi cluster menjadi dasar bagi sistem rekomendasi hybrid.


4.5. HASIL VISUALISASI

Selanjutnya untuk mempermudah dalam memahami cluster atau pengelompokan yang terjadi maka dibuatlah visualisasi yang variatif agar pola dan perbedaan antar cluster dapat terlihat dengan lebih jelas. Beberapa jenis visualisasi yang digunakan antara lain scatter plot, plot distribusi, dan diagram hubungan antar variabel. Visualisasi-visualisasi ini membantu menampilkan pola penyebaran data, jarak antar cluster, serta karakteristik unik tiap kelompok sehingga interpretasi hasil klasterisasi menjadi lebih jelas dan komprehensif.

4.5.1. Scatter Plot

Scatter plot digunakan untuk menampilkan hasil klasterisasi berdasarkan dua variabel utama, yaitu **Price (harga)** pada sumbu X dan **Rating** pada sumbu Y. Setiap titik merepresentasikan satu tempat wisata, sedangkan warna yang berbeda menunjukkan keanggotaan cluster yang berbeda. Tanda silang (centroid) menunjukkan pusat masing-masing cluster hasil K-Means.


Berdasarkan scatter plot, terlihat bahwa sebagian besar tempat wisata berada pada rentang harga rendah hingga menengah (di bawah Rp 200.000) dengan rating relatif tinggi, yaitu antara 4.0 hingga 4.8. Cluster dengan harga tinggi terlihat terpisah secara cukup jelas dari cluster lain, menandakan bahwa algoritma K-Means berhasil membedakan segmen wisata premium dan wisata dengan harga terjangkau. Penyebaran ini menunjukkan bahwa Price dan Rating merupakan fitur yang efektif dalam membentuk pola klasterisasi.



4.5.2. Boxplot

Boxplot menampilkan persebaran nilai **Price** dan **Rating** pada setiap cluster, termasuk median, kuartil, dan potensi outlier.


- Boxplot distribusi **Price per Cluster** digunakan untuk melihat persebaran harga tiket masuk pada setiap cluster, termasuk nilai median, kuartil, serta keberadaan outlier. Hasil visualisasi menunjukkan bahwa sebagian besar cluster, yaitu Cluster 0, Cluster 2, Cluster 3, dan Cluster 4, berada pada rentang harga di bawah Rp 200.000. Cluster 1 memiliki rentang harga yang paling tinggi, yaitu antara Rp 150.000 hingga Rp 900.000, yang menunjukkan bahwa cluster ini merepresentasikan destinasi wisata dengan kategori harga premium. Keberadaan outlier pada beberapa cluster menunjukkan adanya variasi harga yang cukup ekstrem, namun secara umum pola harga antar cluster dapat dibedakan dengan jelas.
- Boxplot distribusi **Rating per Cluster** digunakan untuk menganalisis persebaran nilai rating pada setiap cluster. Hasil visualisasi menunjukkan bahwa seluruh cluster memiliki rating yang relatif tinggi, dengan sebagian besar nilai berada pada rentang 4.0 hingga 5.0.
- Cluster 0 memiliki nilai rating terendah dibandingkan cluster lainnya, dengan rating minimum mencapai 3.4. Sementara itu, Cluster 3 dan Cluster 4 memiliki persebaran rating yang lebih tinggi dan stabil, bahkan mencapai rating maksimal 5.0. Hal ini menunjukkan bahwa mayoritas tempat wisata dalam dataset memiliki kualitas yang baik berdasarkan penilaian pengguna.



4.5.3. Bar Chart

Bar chart digunakan untuk menampilkan jumlah tempat wisata pada setiap cluster (cluster size). Visualisasi ini memberikan gambaran mengenai distribusi data hasil klasterisasi.

Berdasarkan bar chart, Cluster 4 memiliki jumlah tempat wisata terbanyak, yaitu 198 lokasi, diikuti oleh Cluster 3 dengan 168 lokasi. Hal ini menunjukkan bahwa sebagian besar tempat wisata dalam dataset tergolong wisata dengan harga terjangkau dan rating tinggi. Sebaliknya, Cluster 2 hanya memiliki 1 tempat wisata, yang menandakan bahwa karakteristik pada cluster tersebut bersifat sangat spesifik dan jarang ditemui pada data lain.



4.6. HASIL SISTEM REKOMENDASI HYBRID

Sistem rekomendasi hybrid menggabungkan empat faktor yaitu, Distance Score, Similarity(TF-IDF), Rating, dan Price. dengan bobot Distance Score dan Similarity(TF-IDF) bernilai 0,3 kemudian bobot Rating dan Price bernilai 0,2. Model ini bekerja dengan cara:

1. Menentukan titik referensi berdasarkan kota atau nama tempat.
2. Menghitung jarak geografis menggunakan geodesic distance.
3. Menghitung similarity query dengan nama wisata, kota, dan kategori (TF-IDF).

4. Melakukan normalisasi skor untuk tiap faktor.
5. Menghasilkan Hybrid Score.
6. Mengurutkan destinasi berdasarkan skor tertinggi.

Hasil Rekomendasi akan bekerja sebagai berikut ;

Ketika pengguna memasukkan nama kota / tempat, sistem memberikan daftar rekomendasi dengan:

- Harga
- Rating
- Jarak
- Similarity
- Hybrid Score
- Cluster

Sistem ini sangat fleksibel dan dapat di filter berdasarkan: radius maksimal (km), harga maksimal, rating minimal. Sehingga pengguna dapat memperoleh rekomendasi yang sangat personal.

4.7. KELEBIHAN DAN KEKURANGAN SISTEM

Kelebihan dari sistem yang sudah kami buat ini diantaranya ialah : Kombinasi hybrid membuat rekomendasi lebih relevan, kemudian juga Mempertimbangkan faktor geografis secara real. Sistem rekomendasi ini juga mampu memberikan hasil meskipun query tidak spesifik. Dan pada dasarnya cluster membantu sistem memahami segmen wisata dibantu dengan visualisasi yang lebih memudahkan untuk memahami struktur data

Keterbatasan dari sistem rekomendasi yang kami buat ini adalah sistem menghapus data tanpa koordinat dapat mengurangi variasi. Kemudian TF-IDF hanya mengandalkan teks sederhana, sedangkan pada data kami dataset yang berupa teks sangat sederhana. Dan pada sistem yang kami buat, bobot skor masih statis dan belum menggunakan metode optimasi.

Potensi Pengembangan yang dapat dilakukan untuk pembuatan sistem rekomendasi kedepannya ialah bisa menggunakan metode Word2Vec / BERT untuk kesamaan teks. Kemudian dapat ditambahkan faktor waktu tempuh (travel time). Selain itu juga bisa dibuat optimasi bobot hybrid menggunakan metode pembelajaran (ML/DL). Dan tak kalah pentingnya juga apabila pada pengembangan sistem kedepannya dapat dibuat integrasi API peta (Google Maps/OpenStreetMap).

BAB V PENUTUP

5.1. KENDALA

Selama proses pengerjaan proyek ini, terdapat berbagai kendala teknis maupun non-teknis yang muncul di setiap tahap. Kendala-kendala ini menjadi bagian penting dari perjalanan pengembangan karena berpengaruh pada proses analisis, pemodelan, hingga pembuatan sistem rekomendasinya.

Kendala yang pertama yakni terkait dengan kekeliruan kami dalam memahami konsep klasterisasi yang akan kami buat. Jadi pada awal pengajuan judul kami terdapat miskomunikasi mengenai konsep dan alur pengerjaan project tugas akhir ini.

Kemudian memasuki pengerjaan project akhir tentu masih banyak pula kendala yang terjadi selama proses pengerjaan. Setelah konsep dan alur pengerjaan sudah teratasi yakni sudah tersusun dengan baik dan tidak ada miskomunikasi. Kendala yang pertama ialah dalam pengolahan data, diantaranya :

- Terdapat beberapa kolom yang tidak konsisten sehingga perlu dilakukan *cleaning* dan *preprocessing* tambahan.
- Struktur data awal belum sepenuhnya siap pakai untuk clustering ataupun content-based filtering, sehingga memerlukan langkah normalisasi dan encoding yang lebih rinci.
- Penentuan fitur mana yang paling relevan untuk clustering dan rekomendasi sempat membingungkan.

Kendala selanjutnya dalam penentuan jumlah klaster, dimana Pemilihan jumlah klaster tidak langsung terlihat jelas. Kemudian perlu analisis tambahan seperti elbow method dan silhouette score untuk memastikan apakah 4 klaster merupakan jumlah yang optimal. Dan interpretasi karakteristik setiap klaster membutuhkan pemahaman lebih terhadap data.

Kemudian kita menemukan kendala dalam perancangan sistem rekomendasi. Pada awalnya, sistem rekomendasi yang dibutuhkan belum jelas bentuknya. Kami harus memastikan bahwa input pengguna dapat diarahkan ke klaster yang sesuai *tanpa membatasi rekomendasi hanya pada satu klaster*. Ini menjadi tantangan karena sistem harus tetap fleksibel tetapi tetap relevan. Sebelum membuat sistem rekomendasi, kami menyadari bahwa kami tidak memiliki kode content-based filtering sama sekali, sehingga harus membangunnya

dari awal. Untuk sistem rekomendasi yang baik clustering dan content-based harus saling melengkapi, namun awalnya terlihat seperti dua hal yang terpisah. Ada juga kesulitan memahami bagaimana input pengguna yang sangat sederhana bisa dipetakan ke klaster tertentu.

Dan yang terakhir adalah kendala teknis dalam implementasi kode. beberapa hambatan muncul karena tidak semua logika telah dibuat, sehingga perlu menulis banyak bagian dari awal. Ini termasuk pembuatan model similarity, menambah menu interaksi pengguna, hingga memperbaiki alur rekomendasi.

5.2. SOLUSI

Untuk setiap kendala yang muncul selama proses pengerjaan proyek ini, kami melakukan beberapa langkah penyelesaian secara bertahap agar alur pengembangan tetap berjalan dengan baik. Solusi-solusi ini dilakukan baik secara teknis maupun konseptual sehingga seluruh proses analisis data, pemodelan klaster, hingga pembangunan sistem rekomendasi dapat diselesaikan dengan hasil yang optimal.

Kendala pertama yang kami hadapi adalah terkait miskomunikasi dalam memahami konsep klasterisasi dan alur pengerjaan proyek. Untuk mengatasi hal tersebut, kami segera melakukan konsultasi dan bimbingan dengan dosen pengampu yakni ibu Yuni Rosita Dewi, M.Si. kami melakukan klarifikasi ulang mengenai tujuan utama project, metode yang akan digunakan, serta hasil akhir yang diharapkan. Diskusi ini menghasilkan alur kerja yang lebih jelas dan terstruktur, sehingga setiap anggota memahami peran dan langkah pengerjaannya. Dengan penjelasan ulang tersebut, konsep klasterisasi dan sistem rekomendasi dapat dipahami secara menyeluruh sehingga tidak terjadi kebingungan di tahap-tahap selanjutnya.

Setelah konsep awal terselesaikan, kami melanjutkan dengan mengatasi kendala dalam pengolahan data. Dari beberapa kolom yang tidak konsisten, kami menyelesaikannya dengan melakukan data cleaning seperti perbaikan format, penyeragaman nilai, serta penghapusan entri yang tidak valid. Untuk mengatasi struktur data yang belum siap untuk clustering maupun content-based filtering, kami melakukan normalisasi, encoding, dan transformasi fitur sehingga dataset dapat diproses oleh algoritma machine learning. Selain itu, untuk menentukan fitur paling relevan, kami melakukan explorasi data lebih mendalam serta

mencoba beberapa konfigurasi fitur sampai mendapatkan kombinasi yang menghasilkan klaster yang stabil dan rekomendasi yang akurat.

Pada kendala penentuan jumlah klaster, solusi yang kami lakukan adalah menjalankan beberapa metode pembantu keputusan seperti elbow method, silhouette score, dan analisis visual tambahan untuk grafik distribusi data. Setelah melalui analisis tersebut, kami dapat memastikan bahwa jumlah 4 klaster memberikan struktur yang paling seimbang dan informatif. Selain itu, interpretasi karakteristik tiap klaster dilakukan dengan memeriksa nilai rata-rata fitur pada tiap kelompok serta meninjau kembali kategorisasi yang muncul. Dengan cara ini, setiap klaster dapat dipahami dengan baik dan dapat dimanfaatkan dalam sistem rekomendasi.

Untuk kendala dalam perancangan sistem rekomendasi, kami mulai dengan mendefinisikan ulang kebutuhan sistem agar lebih jelas. Kami merancang alur sistem rekomendasi yang menggabungkan dua pendekatan, yaitu cluster-based recommendation dan content-based filtering, sehingga rekomendasi tidak hanya berasal dari klaster yang sama tetapi juga mempertimbangkan kemiripan konten antar destinasi. Kami membangun mekanisme content-based filtering dari awal, termasuk pembuatan TF-IDF, perhitungan cosine similarity, dan pemetaan input pengguna ke fitur yang relevan. Selain itu, kami membuat struktur logika yang memungkinkan input pengguna diarahkan ke klaster yang paling mendekati preferensinya tanpa mengunci rekomendasi pada satu klaster saja. Dengan pendekatan ini, sistem menjadi lebih fleksibel, akurat, dan mampu memberikan rekomendasi lintas-klaster.

Kendala teknis dalam implementasi kode juga kami atasi dengan menyusun struktur program secara bertahap. Kami membuat pondasi kode mulai dari preprocessing, pembentukan model similarity, hingga fungsi menu utama. Setiap bagian diuji secara terpisah untuk memastikan tidak ada error yang menghambat proses selanjutnya. Kami juga melakukan refactoring kode agar lebih rapi serta memperkuat alur rekomendasi sehingga lebih logis dan konsisten. Dengan perbaikan bertahap tersebut, seluruh komponen yang sebelumnya belum ada kini dapat berjalan dengan baik dan membentuk sistem rekomendasi yang utuh.

5.3. KESIMPULAN

Berdasarkan hasil project dan pembahasan yang telah dilakukan, kesimpulan yang dapat kami ambil ialah :

- Metode K-Means Clustering berhasil mengelompokkan tempat wisata berdasarkan kemiripan harga dan rating.

Hasil clustering menunjukkan adanya perbedaan karakteristik yang jelas antar cluster, seperti cluster dengan harga murah dan rating tinggi, cluster dengan harga menengah, hingga cluster dengan harga tinggi. Pengelompokan ini membantu memahami pola distribusi tempat wisata pada dataset.

- Setiap cluster memiliki ciri khas yang dapat digunakan sebagai dasar segmentasi wisata.

Beberapa cluster berisi tempat wisata dengan harga sangat terjangkau dan rating baik, sementara cluster lain berisi destinasi premium dengan harga tinggi. Informasi ini dapat dimanfaatkan untuk analisis lebih lanjut maupun rekomendasi berbasis cluster.

- Content-Based Filtering mampu menghasilkan rekomendasi tempat wisata yang relevan bagi pengguna.

Dengan memanfaatkan informasi teks seperti nama tempat, kota, dan kategori, sistem dapat menemukan destinasi yang memiliki karakteristik mirip dengan preferensi pengguna. Rekomendasi yang dihasilkan terbukti sesuai konteks dan membantu pengguna menemukan alternatif destinasi.

- Kombinasi Clustering dan Content-Based Filtering memberikan sistem rekomendasi yang lebih informatif.

K-Means memberikan gambaran segmentasi destinasi, sedangkan Content-Based Filtering memberikan rekomendasi personal. Kedua metode saling melengkapi, sehingga sistem dapat menyajikan informasi yang lebih kaya dan bermanfaat.

- Sistem rekomendasi yang dibangun mampu berjalan dengan baik dan responsif.

Proses pemuatan data, pengelompokan, hingga pemberian rekomendasi berjalan lancar tanpa hambatan, sehingga sistem dapat digunakan secara efektif oleh pengguna.

DAFTAR PUSTAKA

- [1] A. T. Nugraha, "Implementation of Content-Based Filtering in Tourist Destination Recommendation System in Central Java," *Jurnal Aplikasi Sains Data*, 2025.
- [2] C. Salsabilla dan D. W. Utomo, "Sistem Rekomendasi Wisata Kabupaten Pekalongan dengan Content Based Filtering," *Sistemasi: Jurnal Sistem Informasi*, 2025.
- [3] K. Mandloi dan A. K. Mittal, "Hybrid Music Recommendation System Using Content-based Filtering and K-Mean Clustering Algorithm," *International Journal of Computer Sciences and Engineering*, 2018.
- [4] M. A. Damos, J. Zhu, W. Li, E. Khalifa, A. Hasan, R. Elhabob, A. Hm dan E. Ei, "Enhancing the K-Means Algorithm through a Genetic Algorithm Based on Survey and Social Media Tourism Objectives for Tourism Path Recommendations," *ISPRS : International Journal of Geo-Information*, 2024.
- [5] Z. Abbasi-Moud, H. Vahdat-Nejat dan J. Sadri, "Tourism recommendation system based on semantic clustering and sentiment analysis," *Elsevier : Expert Systems With Applications*, 2020.

Lampiran

- Link Google Colab :

[KA Kel 7 24A](#)

- Link Video :

https://youtu.be/p4If_KLDrJ4